

## 基于支持向量机的高炉炉况诊断方法

曲 飞, 吴 敏, 曹卫华, 何 勇

(中南大学信息科学与工程学院, 湖南 长沙 410083)

**摘 要:** 现实中高炉炉况的征兆样本集是有限的, 常规的基于经验风险最小化原则的方法的应用效果并不理想。支持向量机方法是针对小样本集分类问题提出的, 具有很好的泛化能力, 因此采用最小二乘法支持向量机进行高炉炉况诊断。通过仿真试验验证此方法具有很好的诊断效果。

**关键词:** 高炉炉况; 炉况诊断; 最小二乘法支持向量机

**中图分类号:** TF543.1 **文献标识码:** A **文章编号:** 0449-749X(2007)10-0017-03

## BF Status Diagnosis Approach Based on SVM

QU Fei WU Min CAO Wei-hua HE Yong

(School of Information Science and Engineering, Central South University, Changsha 410083, Hunan, China)

**Abstract** The BF status evidential samples are limited and the approach based on empirical risk minimization principle doesn't work well. SVM (support vector machine) approach is aimed at solving classification problem with a small sample of training and has better ability for generalization. LSSVM approach is proposed to diagnose BF status. Finally the effectiveness of the approach was evaluated by MATLAB simulation.

**Key words** BF status; status diagnosis; LSSVM

高炉炼铁作为钢铁联合企业的上游工序, 其能耗约占企业能耗的 60%, 成本约占 1/3。因此, 炼铁的节能降耗在企业提高经济效益中占有重要的地位, 在挖掘高炉潜力的各种工艺措施之外, 推进高炉冶炼过程的自动化技术的应用是炼铁技术发展的大趋势。

高炉炉况判断是高炉控制决策流程中的一个重要环节。一方面, 高炉炉况判断是制定装料、送风、造渣以及热制度<sup>[1]</sup>等 4 大制度的前提, 从而实现炼铁生产流程的稳定和优化; 另一方面, 高炉炉况的恶化将降低生铁炉的使用寿命, 造成设备损坏, 停产休风等严重后果。因此, 对高炉炉况进行诊断和预报, 实现高炉炉况的实时监测和异常状况预报, 适时、适度地采取相应的调整措施, 避免炉况的恶化, 对实现高炉长时间的稳定、高效运行具有重要作用, 从而促进高炉生产效率的提高, 挖掘高炉生产潜力, 实现节能降耗, 提高企业效益。对此, 各国钢铁企业以及相关研究机构一直致力于高炉炉况诊断系统的研究和应用。

当前, 高炉炉况诊断系统常用的方法主要是专家系统方法和神经网络方法<sup>[2,3]</sup>。由于专家系统存在专家知识难以获得, 规则的提取十分困难, 且容易出现匹配冲突、组合爆炸以及无穷递归等问题, 当前

专家系统更多的应用是和其它方法相结合。神经网络方法则存在下列缺点: 网络结构的选取基于经验; 网络权值学习算法的采用经验风险最小化 (ERM) 原则, 容易产生过学习和欠学习问题, 泛化能力差; 网络权值的求取是非凸问题具有多个最优值, 学习过程中容易陷入局部最优解。

国内部分中小高炉的自动化程度不高, 检测设备不完全, 且检测数据没有实现历史数据存储, 且工艺操作制度更新很快, 高炉炉况诊断系统的征兆数据属于小样本集。由于支持向量机方法是建立在统计学习理论和结构风险最小原理基础上, 根据有限的样本信息在诊断模型的复杂性和学习能力之间进行最佳折衷, 以获得最好的泛化能力, 因此, 可以应用于高炉炉况诊断。

### 1 最小二乘法支持向量机

支持向量机方法是 Vapnik<sup>[4]</sup>等在 20 世纪 70 年代末提出的在有限样本统计学习理论上发展起来的一种新的机器学习方法, 本质上是一种线性二值分类器。对于非线性分类问题, 可以通过核函数将非线性输入空间映射到一个高维线性空间, 在这个新空间中求取最优分类面。

支持向量机法的特点是将最优分类面求取问题

转化为二次规划 (QP, quadratic programming) 求解问题, 根据求解得到最接近分类面的支持向量, 分类判别函数是支持向量的线性组合。由于支持向量机法获得的是最优分类面, 因此, 有较好的分类能力和很好的容错性。

与传统统计学相比, 统计学习理论 (statistical learning theory 或 SLT) 是一种专门研究小样本情况下机器学习规律的理论。该理论针对小样本统计问题建立了一套新的理论体系, 在这种体系下的统计推理规则不仅考虑了对渐近性能的要求, 而且追求在现有有限信息的条件下得到最优结果。

相比其它方法, 支持向量机方法有以下优点:

(1) 它是专门针对有限样本情况的, 其目标是得到现有信息下的最优解而不仅仅是样本数趋于无穷大时的最优值;

(2) 算法最终将转化成为一个二次型寻优问题, 从理论上说, 得到的将是全局最优点, 解决了在神经网络方法中无法避免的局部极值问题;

(3) 算法将实际问题通过非线性变换转换到高维的特征空间, 在高维空间中构造线性判别函数来实现原空间中的非线性判别函数, 保证机器有较好的推广能力, 同时它巧妙地解决了维数问题, 其算法复杂度与样本维数无关。

最小二乘法支持向量机方法是 Suykens<sup>[5]</sup>等在 Vapnik 的支持向量机方法的基础上提出的一种改进方法, 它们之间的主要区别是最小二乘法支持向量机方法用最小二乘法进行参数估计替代了原来支持向量机通过二次规划求解分类面参数, 其原理如下:

对于线性可分的分类问题, 分类线方程为  $x \cdot w + b = 0$  对它进行归一化, 使得对线性可分的样本集  $(x_i, y_i)$ ,  $i = 1, \dots, N$ ,  $x_i \in R^d$ ,  $y_i \in \{+1, -1\}$  满足:

$$y_i[(w \cdot x_i) + b] - 1 \geq 0 \quad i = 1, \dots, N \quad (1)$$

对非线性不可分问题, 通过非线性映射  $\Phi: R^d \rightarrow H$  将输入空间的样本映射到高维的特征空间  $H$  中, 同时引入松弛因子  $\xi$  以解决不可分问题。根据 SRM 原则 LSSVM 构造如下的最小化目标函数:

$$\min Q(w, \xi) = \frac{1}{2} w^T w + \frac{1}{2} C \sum_{i=1}^N \xi_i^2 \quad (2)$$

$$\text{st } y_i(w^T \Phi(x_i) + b) = 1 - \xi_i \quad (3)$$

对偶问题的 Lagrange 函数可以写成:

$$L = Q(w, \xi) - \sum_{i=1}^N \alpha_i (y_i(w^T \Phi(x_i) + b) - 1 + \xi_i) \quad (4)$$

式中  $\alpha_i$  为 Lagrange 乘子。根据 KKT 条件:

$$\frac{\partial L}{\partial w} = 0 \quad w = \sum_{i=1}^N \alpha_i y_i \Phi(x_i) \quad (5)$$

$$\frac{\partial L}{\partial b} = 0 \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (6)$$

$$\frac{\partial L}{\partial \xi_i} = 0 \quad \alpha_i = C \xi_i \quad (7)$$

经过替换, 得到下方程:

$$\begin{cases} \sum_{i=1}^N \alpha_i y_i = 0 \\ \sum_{i=1}^N \alpha_i y_i y_j K(x_i, x_j) + \frac{1}{2} \alpha_j + b = 1 \end{cases} \quad j = 1, \dots, N \quad (8)$$

根据上面  $N+1$  个方程式, 采用最小二乘法得到  $b$  和  $\alpha_i$  值。由于  $w = \sum_{i=1}^N \alpha_i y_i \Phi(x_i)$ , 最终得到分类函数:

$$f(x) = \text{sign}(\sum_{i=1}^N \alpha_i y_i \Phi(x_i) + b) \quad (9)$$

式中  $K(x_i, x_j) = \Phi^T(x_i) \Phi(x_j)$  为核函数。

## 2 炉况诊断仿真

针对某钢铁公司高炉的运行情况, 选取高炉发生较频繁的 3 种异常炉况进行仿真试验, 采用 LSSVM 方法建立对正常炉况以及塌料、悬料、向热 4 个炉况分类器。分类器的构建采用一对多方式, 核函数采用径向基函数 (RBF)。根据现场专家判断和分析共选择 705 组炉况数据, 其中正常炉况数据 326 组, 塌料异常炉况数据 141 组, 悬料异常炉况数据 71 组, 向热异常炉况数据 167 组。

根据高炉冶炼原理和故障征兆描述分析确定炉况诊断系统输入参数为: 风温, 风量, 风压, 全压差, 炉顶 1~4 号上升管的温度, 炉料下降的速度, 冷却水的压力、温度和流量, 炉壁温度等以及各参数的变化量共 23 个参数。由于料位不是一个连续的测量量, 因此没有作为支持向量机的输入参数。为了求取最优分类器参数, 采用  $k$ -折交叉验证 (在此选择  $k=5$ ), 即将炉况征兆数据分为 5 组, 选取其中 4 组作为训练集, 另外一组为测试集, 选取误判、错判最少的分类器作为最终的分类器。

最小二乘法支持向量机方法的参数  $C$  和径向基函数的参数  $\delta$  由人工给定, 因此, 它们的选取对分类结果有一定的影响。为此, 选取  $\delta$  (或  $C$ ) 为某些固定值, 计算  $C$  (或  $\delta$ ) 为不同值时的误分率。图 1(a) 为  $C=11$  时不同参数  $\delta$  的误分率, 图 1(b) 为  $\delta$




图 1  $C = 11$ ( a)、 $\delta = 13$ ( b)时 SVM 分类器的误分率

Fig 1 Error of SVM classifier under  $C = 11$ ( a) and  $\delta = 13$ ( b)

= 13时不同参数  $C$  的误分率。

通过分析,在  $C$  值和  $\delta$  值较大或较小时,分类错误率都很高。根据上面方法确定  $C$  值和  $\delta$  值的范围,采用遗传算法对  $C$  值和  $\delta$  值的最优值搜索,最终选取了合适的  $C$  值和  $\delta$  值,使各分类器具有很好的分类效果,其分类结果如表 1 所示。

从仿真结果可见,正常炉况的诊断准确率为 98%,也即异常炉况的诊断准确率为 98%,只是在各种异常炉况的判断上误报率略有上升,但诊断准确率仍能达到 90% 以上。

3 结论

(1) 系统仿真结果表明,人为确定的参数(如 RBF 核函数的  $C$  值和  $\delta$  值)对分类效果有很大的影响。

表 1 各分类器在 5 折交叉验证下的分类效果

Table 1 Classification results of SVM classifier with 5-fold cross-validation

序号	炉况诊断误分率				
	正常	塌料	悬料	向热	平均
1	1.39	5.7	6.3	2.1	3.9
2	0	6.3	6.3	2.1	3.7
3	0	8.3	5.6	2.8	4.2
4	0.69	4.2	6.3	3.5	3.7
5	0.69	4.2	5.6	4.9	3.8
平均	0.60	5.7	6.0	3.1	

- (2) 在优化的参数下,正常炉况的诊断准确率高于 98%,各异常炉况的诊断准确率高于 90%。SVM 方法在高炉炉况诊断方面具有很好的效果,可应用于高炉的故障诊断领域。
- (3) 由于支持向量机方法求取的分类面为最大间隙分类面,因此有较好的泛化能力。
- (4) 对于高炉操作人员来说,如果给出炉况的模糊化值对高炉操作更有指导意义。SVM 分类器求取的是数据向量到最优分类面的距离,通过二值判别函数得出分类判断,若将二值判别函数变换为实域映射函数即可实现趋势预报。

参考文献:

[1] 宋建成. 高炉炼铁理论与操作 [M]. 北京: 冶金工业出版社, 2005.

[2] 朱大奇, 于盛林. 基于知识的故障诊断方法综述 [J]. 安徽工业大学学报, 2002, 19(3): 197-204. ( ZHU Da-qí YU Sheng-lin. Survey of Knowledge-Based Fault Diagnosis Methods [J]. J of Anhui University of Technology, 2002, 19(3): 197-204. )

[3] 张登峰, 王执铨, 孙金生. 控制系统故障诊断的理论与技术 [J]. 数据采集与处理, 2002, 17(3): 293-299. ( ZHANG Deng-feng WANG Zhi-quan SUN Jin-sheng. Fault Diagnosis Technology in Control Systems [J]. Journal of Data Acquisition & Processing, 2002, 17(3): 293-299. )

[4] Vapnik V N. The Nature of Statistical Learning Theory [M]. 2nd ed. New York: Springer-Verlag, 1999.

[5] Suykens J A K, Vandewalle J. Least Squares Support Vector Machine Classifiers [J]. Neural Processing Letters, 1999, 9(3): 293-300.